2º curso / 2º cuatr.

Grados en Ing. Informática

Arquitectura de Computadores

Tema 4. Arquitecturas con Paralelismo a nivel de Instrucción (ILP)

Material elaborado por Mancia Anguita y Julio Ortega Profesores: Mancia Anguita, Maribel García y Christian Morillas







Lecciones

AC A PIC

- Lección 11. Microarquitecturas ILP. Cauces Superescalares
- Lección 12. Consistencia del procesador y Procesamiento de Saltos
- Lección 13. Procesamiento VLIW

2º curso / 2º cuatr. Grados en Ing. Informática

Arquitectura de Computadores Tema 4

Lección 11. Microarquitecturas ILP. Cauces Superescalares

Material elaborado por Mancia Anguita y Julio Ortega Profesores: Mancia Anguita, Maribel García y Christian Morillas







Lecciones

AC A PIC

- Lección 11. Microarquitecturas ILP. Cauces Superescalares
 - > Introducción: Motivación y Nota Histórica
 - Paralelismo entre instrucciones (ILP). Orden en Emisión y Finalización
 - Cauces superescalares
- Lección 12. Consistencia del procesador y Procesamiento de Saltos
- Lección 13. Procesamiento VLIW

Bibliografía

AC A PIC

Fundamental

- > M. Anguita, J. Ortega: "Fundamentos y Problemas de Arquitectura de Computadores". Ed. Avicam, 2016.
- Capítulo 3. Secc. 3.1, 3.3.1, 3.3.2, 3.3.3. J. Ortega, M. Anguita, A. Prieto. *Arquitectura de Computadores*.
 Thomson, 2005. ESIIT/C.1 ORT arq

Complementaria

➤ Sima and T. Fountain, and P. Kacsuk.

Advanced Computer Architectures: A Design Space

Approach. Addison Wesley, 1997. ESIIT/C.1 SIM adv

Contenido de la Lección 11

AC A PTC

- > Introducción: Motivación y Nota Histórica
- Paralelismo entre instrucciones (ILP). Orden en Emisión y Finalización
- Cauces superescalares

Arquitecturas con DLP, ILP y TLP (thread=flujo de control)

AC PIC

Arq. con **DLP** (*Data Level Parallelism*)

Tema 5

Ejecutan las operaciones de una instrucción concurr. o en paralelo

Unidades funcionales vectoriales o SIMD Arq. con **ILP** (*Instruction Level Parallelism*)

Tema 4
Ejecutan
múltiples
instrucciones
concurr. o en
paralelo

Cores escalares segmentados, superescalares o VLIW/EPIC

Arq. con **TLP** (*Thread Level Parallelism*) explícito y **una** instancia de SO

Temas 3, 5

Ejecutan múltiples flujos de control concurr. o en paralelo

Cores que modifican la arquit. escalar segmentada, superescalar o VLIW/EPIC para ejecutar threads concurr. o en

paralelo

Multiprocesadores:
 ejecutan
 threads en
paralelo en un
computador
con múltiples
cores (incluye
multicores)

Arq. con TLP explícito y múltiples instancias SO

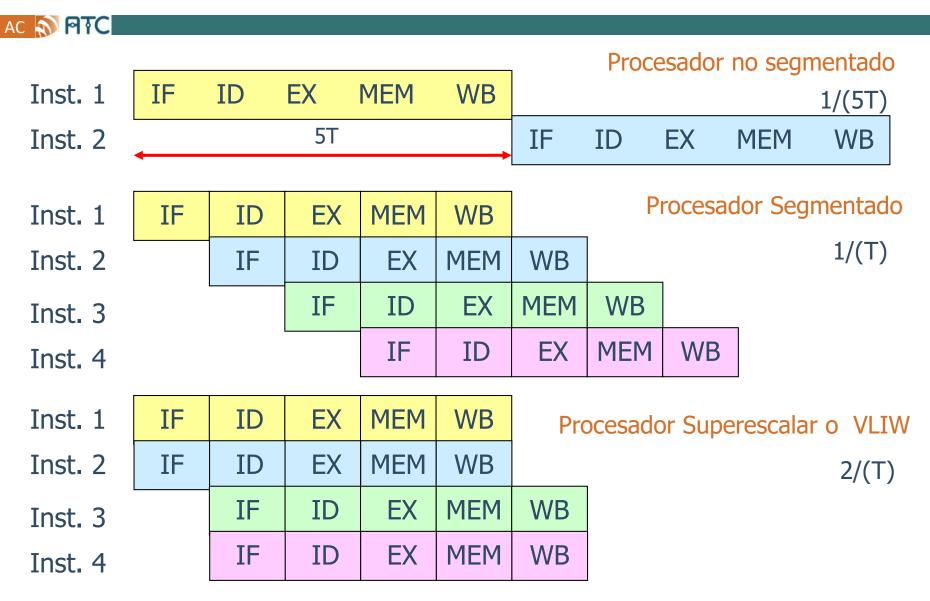
IC.SCAP

Ejec. múltiples flujos de control en paralelo

Multicomputadores: ejecutan

ejecutan
threads en
paralelo en un
sistema con
múltiples
computadores

Paralelismo entre Instrucciones



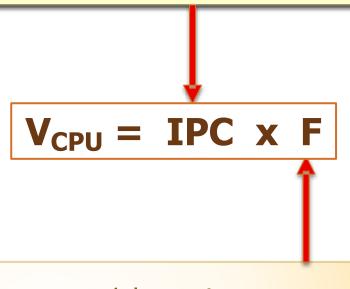
Mejora de las Prestaciones de los Procesadores



Más transistores por circuito integrado →

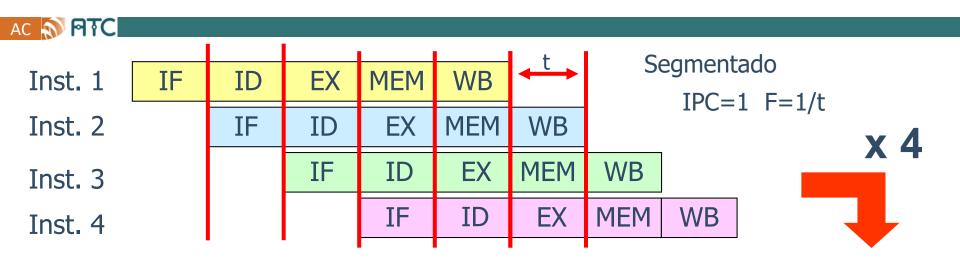
Microarquitecturas más complejas en un solo CI: Paralelismo entre Instrucciones (Procesadores Superescalares)

Mejora de la Tecnología de Fabricación de CI basada en el Silicio → Reducción del tamaño de los transistores + Aumento del tamaño del dado



Se reduce la longitud de puerta del transistor y con ello el tiempo de conmutación → Mayores frecuencias de funcionamiento

Evolución de Microarquitecturas I



Aumento de IPC

Superescalar o VLIW IPC=2 F=1/t

MEM WB Inst. 1 ID IF EX **IF** MEM **WB** Inst. 2 ID EX MEM **WB** IF ID EX Inst. 3 MEM EX WB IF ID Inst. 4

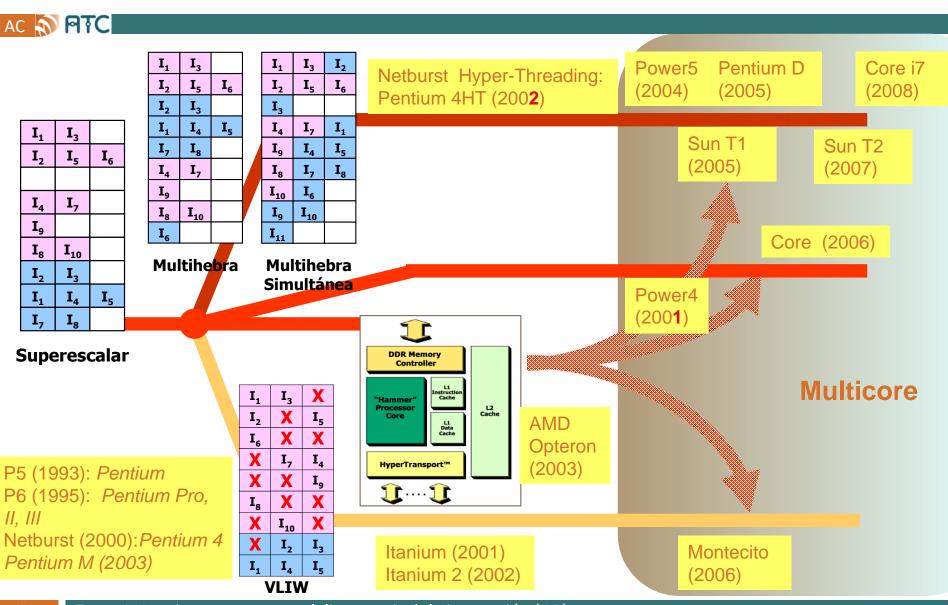
Aumento de IPC y F

IPC=2 F=2/t

+/2

						ひと
Inst. 1	IF	ID	EX	М	WB	\leftrightarrow
Inst. 2	IF	ID	EX	М	WB	
Inst. 3		IF	ID	EX	M	WB
Inst. 4		IF	ID	EX	M	WB

Evolución de Microarquitecturas II



Nota histórica. DLP y ILP (*Instruction Level Parallelism*)

AC A PTC

- DLP (Data Level Parallelism)
 - Unidades funcionales (o de ejecución) SIMD (o multimedia)
 - 1989 (Intel i860). 1991 (motorola M88110). 1993 (repertorio MAX en HP PA: PA7100LC). 1995 (repertorio VIS en Sun Sparc: Ultra I). 1997 (repertorio MMX en Intel x86: Pentium MMX). 1999 (repertorio SSE en Intel x86: Pentium III; repertorio Altivec en IBM Power: PowerPC 8000)

ILP (Instruction Level Parallelism):

TEMA 4

- Procesadores/cores segmentados
 - **1961** (IBM 7030). **1982** (chip Intel i286, Motorola 68020). **1986** (chip MIPS R2000). **1987** (chip AMD Am29000). **1988** (chip Sun Sparc)...
- > Procesadores con múltiples unidades funcionales
 - **1967** (IBM 360/91) ...
- Procesadores/cores superescalares
 - **1989** (chip Intel 960CA (3)). **1990**: (chip IBM Power1 (4)). **1992**: (chips DEC α21064 (2/4), HP PA 7100 (2/2), Sun SuperSparc (3/5)) ...
- Procesadores/cores VLIW
 - 1990 (chip DSP Intel i860 (2)).1997 (chip DSP TMS320C6x (8)). 2001 (chip Intel Itanium)...

Contenido de la Lección 11

AC A PTC

- > Introducción: Motivación y Nota Histórica
- Paralelismo entre instrucciones (ILP). Orden en Emisión y Finalización
- Cauces superescalares

Ordenaciones en una secuencia de instrucciones

AC A PIC

- En una secuencia de instrucciones se pueden distinguir tres tipos de ordenaciones:
 - > El orden en que se captan las instrucciones (el orden de las instrucciones en el código)
 - > El orden en que las instrucciones se ejecutan
 - > El orden en que las instrucciones cambian los registros y la memoria.
- El procesador superescalar debe ser capaz de identificar el paralelismo entre instrucciones (ILP) que exista en el programa y organizar la captación, decodificación y ejecución de instrucciones en paralelo, utilizando eficazmente los recursos existentes (el paralelismo de la máquina).
- Cuanto más sofisticado sea un procesador superescalar, menos tiene que ajustarse a la ordenación de las instrucciones según se captan, para la ejecución y modificación de los registros, de cara a mejorar los tiempos de ejecución. La única restricción es que el resultado del programa sea correcto.

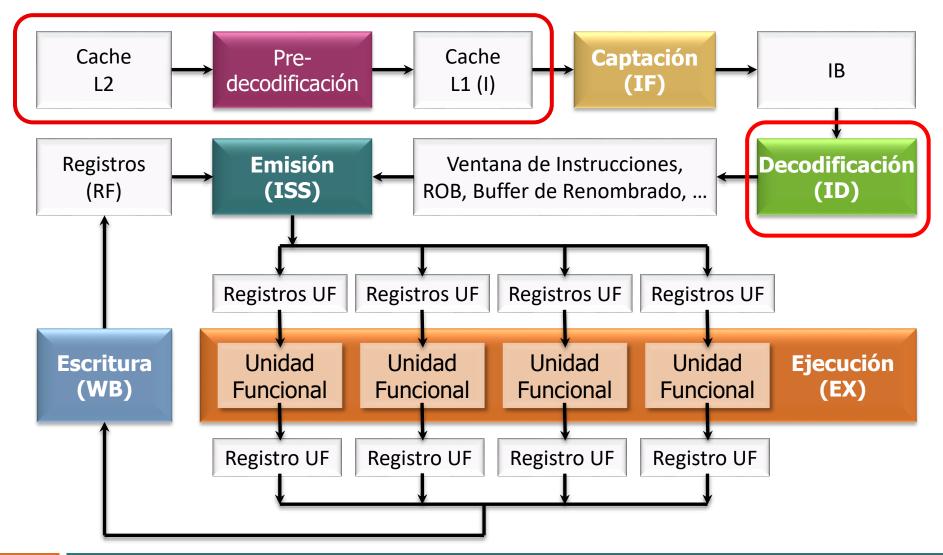
Contenido de la Lección 11

AC A PIC

- Introducción: Motivación y Nota Histórica
- Paralelismo entre instrucciones (ILP). Orden en Emisión y Finalización
- Cauces superescalares
 - > Decodificación Paralela y Predecodificación
 - > Emisión Paralela de Instrucciones. Estaciones de Reserva
 - Renombramiento de registros

Etapas de un Procesador Superescalar: Predecodificación I





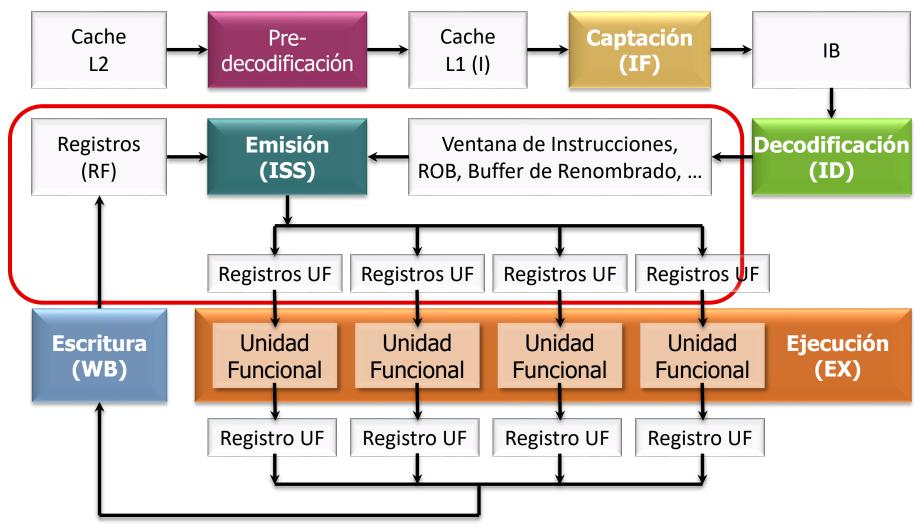
Contenido de la Lección 11

AC A PIC

- Introducción: Motivación y Nota Histórica
- Paralelismo entre instrucciones (ILP). Orden en Emisión y Finalización
- Cauces superescalares
 - > Decodificación Paralela y Predecodificación
 - Emisión Paralela de Instrucciones. Estaciones de Reserva
 - Renombramiento de registros

Etapas de un Procesador Superescalar: Emisión Paralela de Instrucciones





Ventana de Instrucciones

AC AN PITC

- La ventana de instrucciones almacena las instrucciones pendientes
 - > todas, si la ventana es centralizada, o las de un tipo determinado, si es distribuida
- Las instrucciones se cargan en la ventana una vez decodificadas
 - > Se utiliza un bit para indicar si un operando está disponible (se almacena el valor o se indica el registro desde donde se lee) o no (se almacena la unidad funcional desde donde llegará el operando)
- Una instrucción puede ser emitida cuando tiene todos sus operandos disponibles y la unidad funcional donde se procesará.

> Hay diversas posibilidades para el caso en el que varias instrucciones estén disponibles (características de los buses, etc.) Dato no válido

Ejemplo de Ventana de Instrucciones

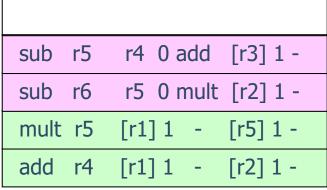
dato) opcode address rb_entry ok1 operand2 operand1 ok2 MULTD loop + 0x42 1 0 0 1 1) 0 1 LD loop 0 0 Dato válido

Lugar donde se almacenará el resultado (igual a 0)

(indica desde dónde se recibirá el

Emisión Paralela de Instrucciones: Ordenada





add/sub: 2

mult: 1

Ventana de Instrucciones

[<mark>1]</mark> add	l r4,r1,r2	(2)
-----------------------	------------	-----

[2] mult r5,r1,r5 (5)

[3] sub r6,r5,r2 (2)

[4] sub r5,r4,r3 (2)

	7
\ \	

Se han emitido [1] y [2]

sub	r5	r4 0 add	[r3] 1 -
sub	r6	r5 0 mult	[r2] 1 -

Instrucc.	ISS	EXE
add	(1)	(2)-(3)
mult	(1)	(2)-(6)
sub	(7)	(8)-(9)
sub	(7)	(8)-(9)



Ha terminado [1]

Ha terminado [2]: pueden emitirse [3] y [4]

sub r5 [r4] 1 - [r3] 1 - sub r6 r5 0 mult [r2] 1 -



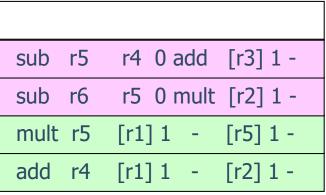
sub r5 [r4] 1 - [r3] 1 - sub r6 [r5] 1 - [r2] 1 -

Emisión Paralela de Instrucciones: Desordenada

Ventana de

Instrucciones

AC AC PIC



add/sub: 2 mult: 1

[1] add r4,r1,r2 (2)

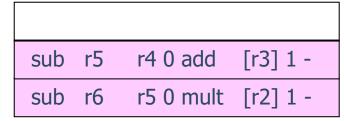
[2] mult r5,r1,r5 (5)

[3] sub r6,r5,r2 (2)

[4] sub r5,r4,r3 (2)

+

Se han emitido [1] y [2]



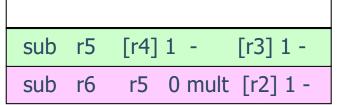


Instrucc.	ISS	EXE
add	(1)	(2)-(3)
mult	(1)	(2)-(6)
sub	(7)	(8)-(9)
sub	(4)	(5)-(6)



Ha terminado [1]

Se ha emitido [4] y ha terminado [2]: puede emitirse [3]





sub r6 [r5] 1 - [r2] 1 -

Ejemplo de Emisión Paralela de Instrucciones Ordenada

Ventana de

Instrucciones



sub	r5	r4 0 add	[r3] 1 -
sub	r6	r5 0 mult	[r2] 1 -
mult	r5	[r1] 1 -	[r5] 1 -
add	r4	[r1] 1 -	[r2] 1 -

add/sub: 1 mult: 1

[1] add r4,r1,r2 [2] mult r5,r1,r5

r5 (5)

(2)

[3] sub r6,r5,r2 (2)

[4] sub r5,r4,r3 (2)

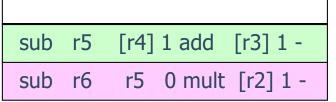
Se han emitido [1] y [2]

sub	r5	r4 0 add	[r3] 1 -
sub	r6	r5 0 mult	[r2] 1 -

Instrucc.	ISS	EXE
add	(1)	(2)-(3)
mult	(1)	(2)-(6)
sub	(7)	(8)-(9)
sub	(10)	(11)-(12)

Ha terminado [1]

Ha terminado [2] y se ha emitido [3]. Cuando la unidad quede libre se emitirá [4]





sub r5 [r4] 1 - [r3] 1 -

Ejemplo de Emisión Paralela de Instrucciones Desordenada



sub r5 r4 0 add [r3] 1 sub r6 r5 0 mult [r2] 1 mult r5 [r1] 1 - [r5] 1 add r4 [r1] 1 - [r2] 1 -

add/sub: 1

mult: 1

Ventana de Instrucciones [1] add r4,r1,r2 (2)

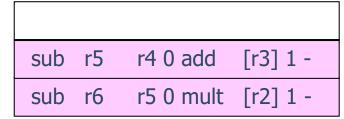
[2] mult r5,r1,r5 (5)

[3] sub r6,r5,r2 (2)

[4] sub r5,r4,r3 (2)



Se han emitido [1] y [2]



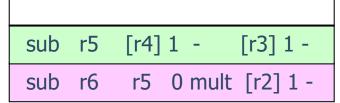


Instrucc.	ISS	EXE
add	(1)	(2)-(3)
mult	(1)	(2)-(6)
sub	(7)	(8)-(9)
sub	(4)	(5)-(6)



Ha terminado [1]

Se ha emitido [4] y ha terminado [2]: puede emitirse [3]

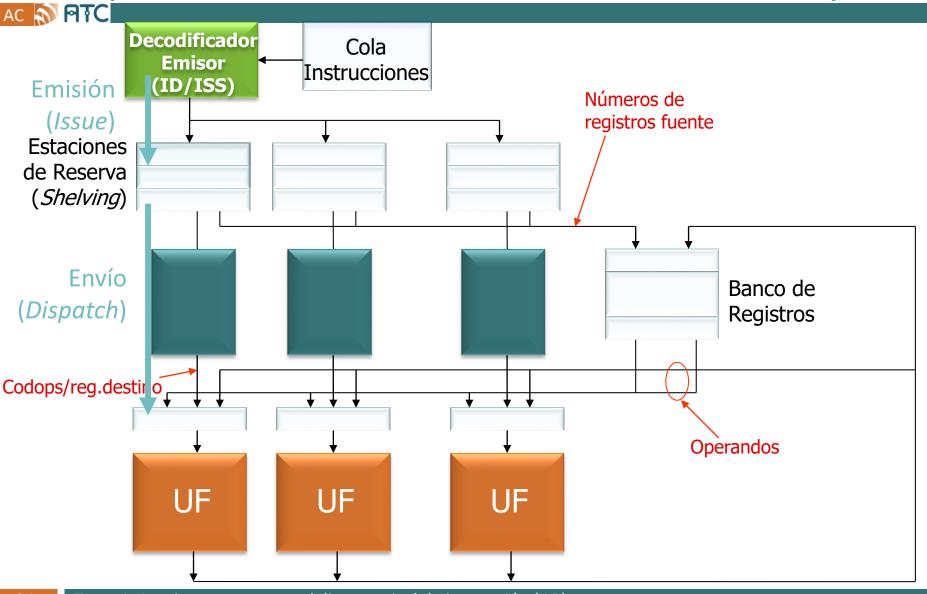




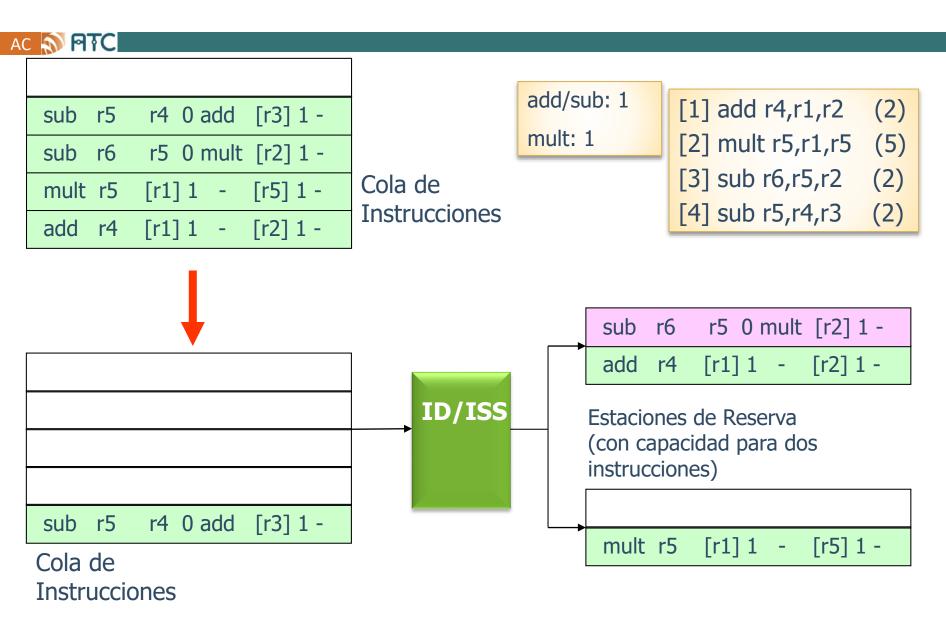
sub r6 [r5] 1 - [r2] 1 -

Estaciones de Reserva I

(Ventana de Instrucciones Distribuida)



Ejemplo de Emisión con Estaciones de Reserva



Alternativas para el Envío a las Unidades Funcionales



Reglas de Selección: Se determina las instrucciones que pueden enviarse

Las instrucciones ejecutables

Reglas de Arbitraje: Instrucción que se envía si hay varias ejecutables

La más antigua entre las ejecutables

Orden de Envío: Ordenadas, Desordenadas, o Parcialmente ordenadas (ciertas instrucciones no ejecutables bloquean instrucciones de un tipo, pero no de otros)



Ordenada: Power 1 (90), PowerPC 603 (93), Am29000 (95)

Parcialmente ordenada: Power 2 (93), PowerPC 604 (95), PowerPC 620(96)

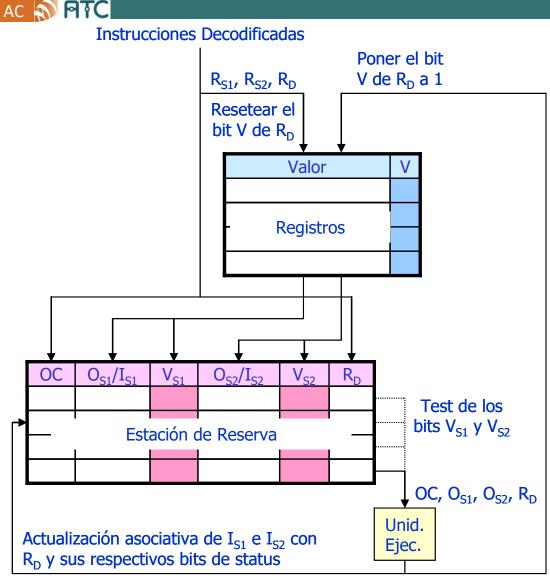
Desordenada: ES/9000(92), PentiumPro (95), R10000(96), PA8000 (96)

Velocidad de Envío: Número de instrucciones que se envían por ciclo

Una por ciclo: PowerPC 603 (93), PowerPC 604 (94), PowerPC 620 (95)

Varias por Ciclo: Sparc64(95), R10000 (96), PA8000 (96), PentiumPro (95)

Comprobación de los Operandos



Comprobación de los bits de validez en la ventana o estación de reserva

(Captación de los operandos en la emisión)

- OC: Código de operación
- R_{S1}, R_{S2}: Registros fuente
- R_D: Registro de destino
- O_{S1}, O_{S2}: Operandos fuente
- I_{S1}, I_{S2}: Identificadores de los operandos fuente
- V_{S1}, V_{S2}: Bits válidos de los operandos fuente

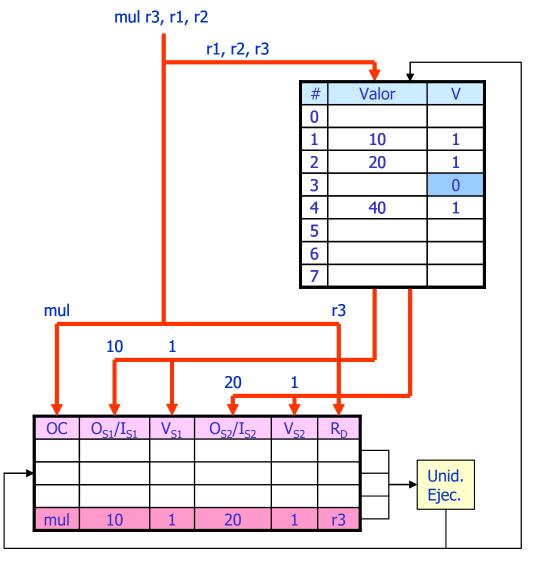
Ejemplo de uso de Estaciones de Reserva I

AC AC PIC

Ciclo i: mul r3, r1, r2
Ciclo i+1: add r5, r2, r3
add r6, r3, r4

Ciclo i:

- Se emite la instrucción de multiplicación, ya decodificada, a la estación de reserva
- Se anula el valor de r3 en el banco de registros
- Se copian los valores de r1 y r2 (disponibles) en la estación de reserva



Ejemplo de uso de Estaciones de Reserva II

AC N PTC

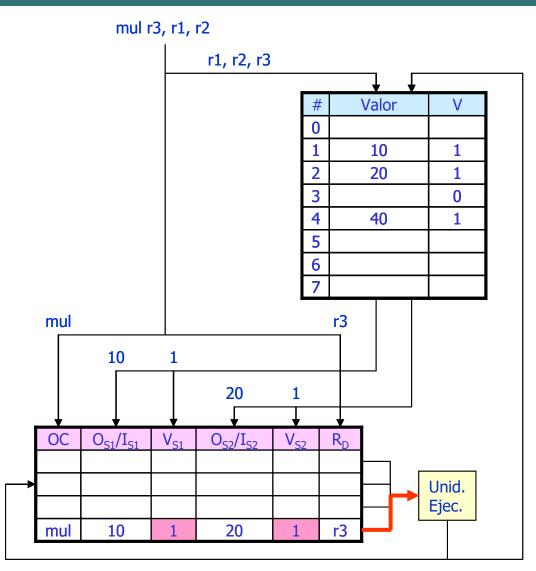
Ciclo i: mul r3, r1, r2

Ciclo i+1: add r5, r2, r3

add r6, r3, r4

Ciclo i + 1:

- La operación de multiplicación tiene sus operadores preparados (V_{S1} = 1 y V_{S2} = 1)
- Así que puede enviarse a la unidad de ejecución



Ejemplo de uso de Estaciones de Reserva III

AC MATC

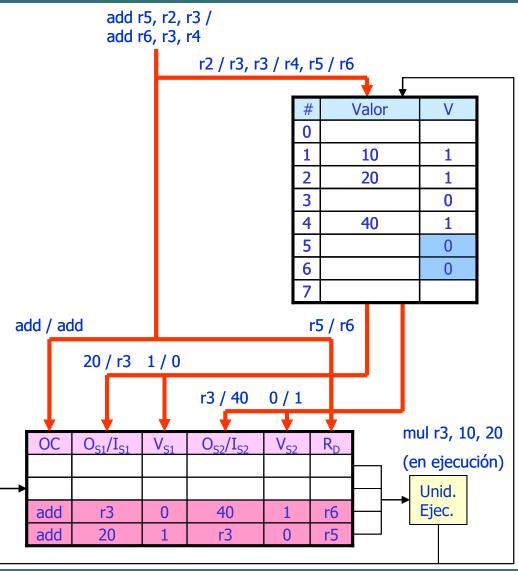
Ciclo i: mul r3, r1, r2

Ciclo i+1: add r5, r2, r3

add r6, r3, r4

Ciclo i + 1 (*cont.*):

- Se emiten las dos instrucciones de suma a la estación de reserva
- Se anulan los valores de r5 y r6 en el banco de registros
- Se copian los valores de los operandos disponibles y los identificadores de los operandos no preparados



Ejemplo de uso de Estaciones de Reserva IV



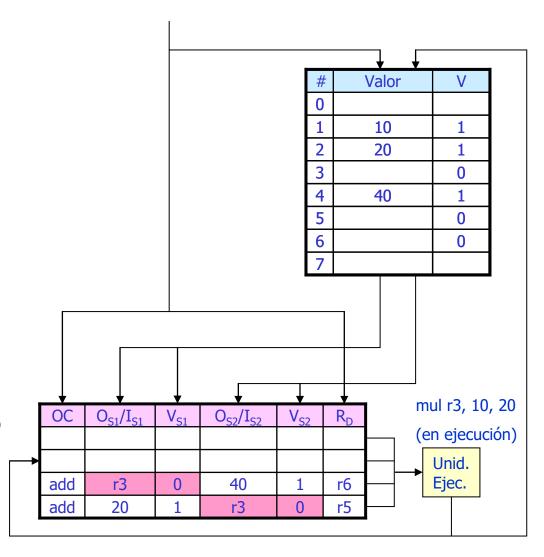
Ciclo i: mul r3, r1, r2

Ciclo i+1: add r5, r2, r3

add r6, r3, r4

Ciclos i + 2 ... i + 5:

- La multiplicación sigue ejecutándose
- No se puede ejecutar ninguna suma hasta que esté disponible el resultado de la multiplicación (r3)



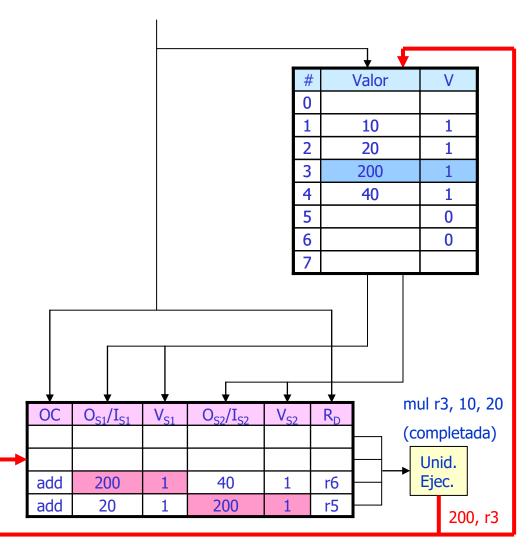
Ejemplo de uso de Estaciones de Reserva V

AC N PTC

Ciclo i: mul r3, r1, r2
Ciclo i+1: add r5, r2, r3
add r6, r3, r4

Ciclo i + 6:

- Se escribe el resultado de la multiplicación en el banco de registros y en las entradas de la estación de reserva
- Se actualizan los bits de disponibilidad de r3 en el banco de registros y en la estación de reserva



Ejemplo de uso de Estaciones de Reserva VI



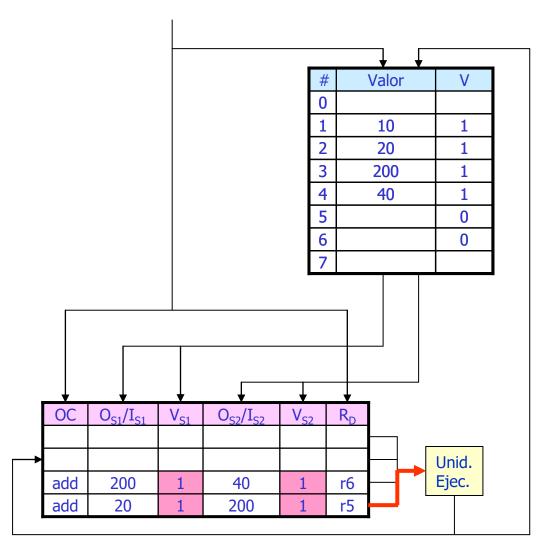
Ciclo i: mul r3, r1, r2

Ciclo i+1: add r5, r2, r3

add r6, r3, r4

Ciclo i + 6 (*cont.*):

- Las sumas tienen sus operadores preparados (VS1 = 1 y VS2 = 1)
- Así que pueden enviarse a la unidad de ejecución



Ejemplo de uso de Estaciones de Reserva VII



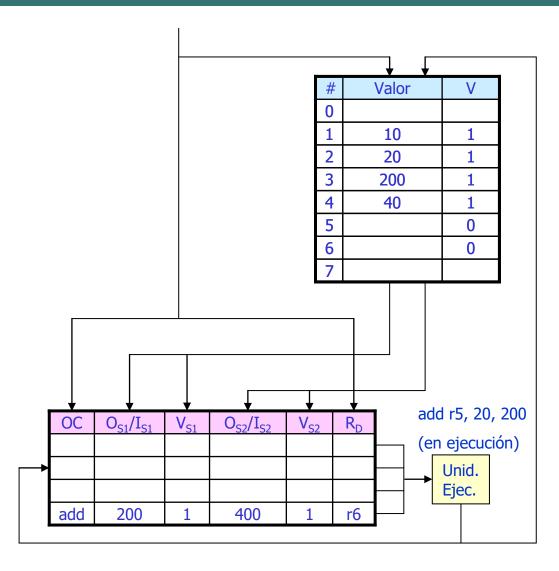
Ciclo i: mul r3, r1, r2

Ciclo i+1: add r5, r2, r3

add r6, r3, r4

Ciclo i + 6 (*cont.*):

 Como sólo hay una unidad de ejecución, se envía la instrucción más antigua de la estación de reserva, la primera suma

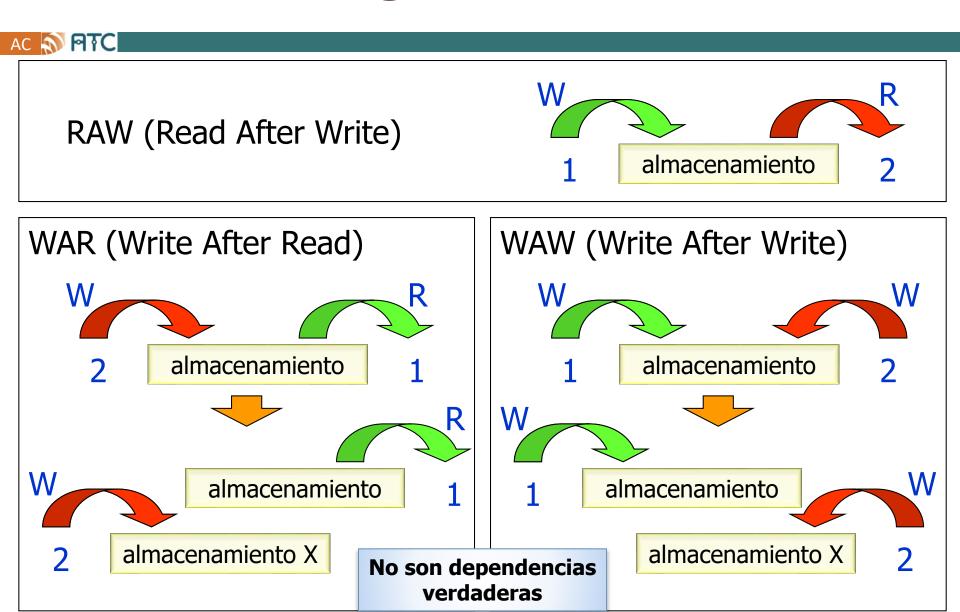


Contenido de la Lección 11

AC A PIC

- Introducción: Motivación y Nota Histórica
- Paralelismo entre instrucciones (ILP). Orden en Emisión y Finalización
- Cauces superescalares
 - > Decodificación Paralela y Predecodificación
 - > Emisión Paralela de Instrucciones. Estaciones de Reserva
 - Renombramiento de registros

Riesgos de Datos



Renombramiento de Registros

AC MATC

Técnica para evitar el efecto de las dependencias WAR, o Antidependencias (en la emisión desordenada) y WAW, o Dependencias de Salida (en la ejecución desordenada).

$$R3 := R3 - R5$$

$$R4 := R3 + 1$$

$$R3 := R5 + 1$$



Cada escritura se asigna a un registro físico distinto

$$R3b := R3a - R5a$$

$$R4a := R3b + 1$$

$$R3c := R5a + 1$$

Sólo RAW

R.M. Tomasulo (67)

Implementación Estática: Durante la Compilación

Implementación Dinámica: Durante la Ejecución (circuitería adicional y registros extra)

Características de los Buffers de Renombrado

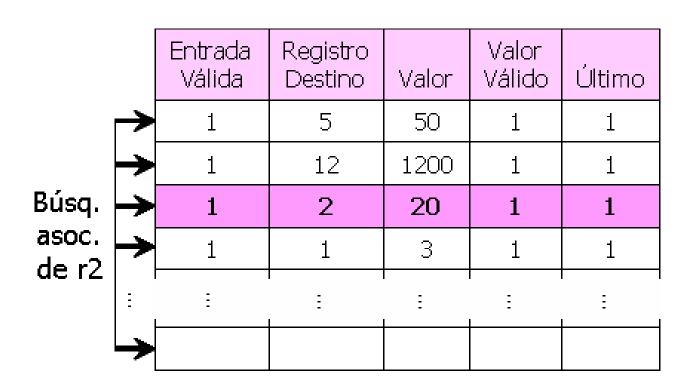
- Tipos de Buffers (separados o mezclados con los registros de la arquitectura)
- Número de Buffers de Renombrado
- Mecanismos para acceder a los Buffers (asociativos o indexados)

Velocidad del Renombrado

Máximo número de nombres asignados por ciclo que admite el procesador

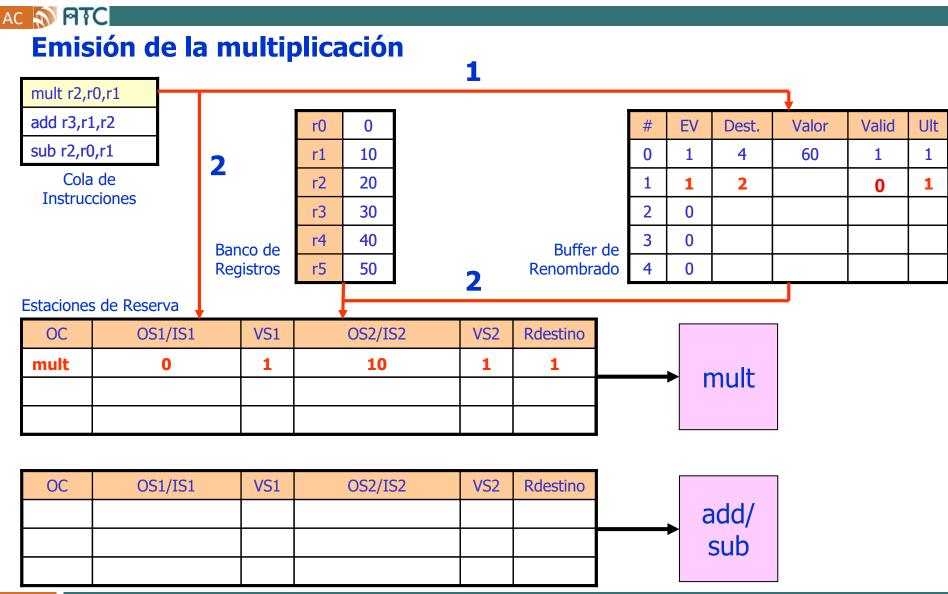
Buffers de Renombramiento



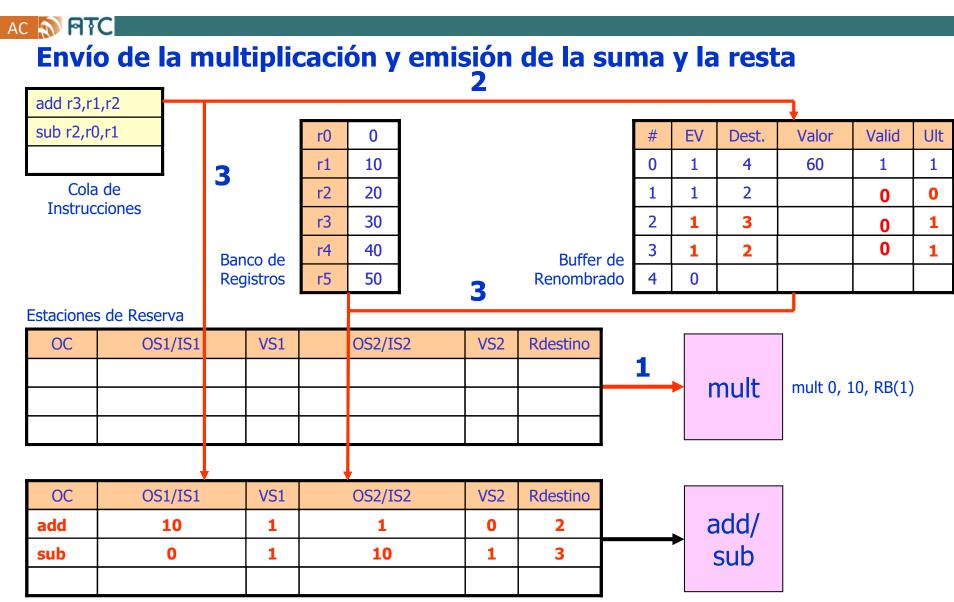


Permite varias escrituras pendientes a un mismo registro El bit de último se utiliza para marcar cual ha sido la más reciente

Algoritmo de Tomasulo I



Algoritmo de Tomasulo II



Algoritmo de Tomasulo III



Envío de la resta

Cola de Instrucciones

r0 0
r1 10
r2 20
r3 30
r4 40
r5 50

Banco de Registros

EV Valor Valid Dest. Ult 60 1 1 4 1 2 0 3 1 1 3 1 2 1 0

Estaciones de Reserva

C	C	OS1/IS1	VS1	OS2/IS2	VS2	Rdestino			
								mult	mult 0, 10, RB(1)
								muit	maic 0, 10, ND(1)

Buffer de

Renombrado

OC	OS1/IS1	VS1	OS2/IS2	VS2	Rdestino
add	10	1	1	0	2

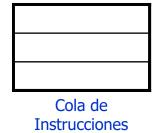
add/ sub

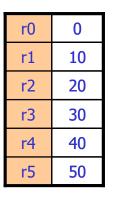
sub 0, 10, RB(3)

Algoritmo de Tomasulo IV



Termina la resta





OS2/IS2

Banco de Registros

VS1

#	EV	Dest.	Valor	Valid	Ult
0	1	4	60	1	1
1	1	2		0	0
2	1	3		0	1
3	1	2	-10	1	1
4	0				

Estaciones de Reserva

OS1/IS1

OC

Ī	0.0	004 (704) (C4	0.00 /700	1,400	5.1		1
								1
ŀ							muit	maic 0, 10, RB(1)
							 mult	mult 0, 10, RB(1)

VS2

Buffer de

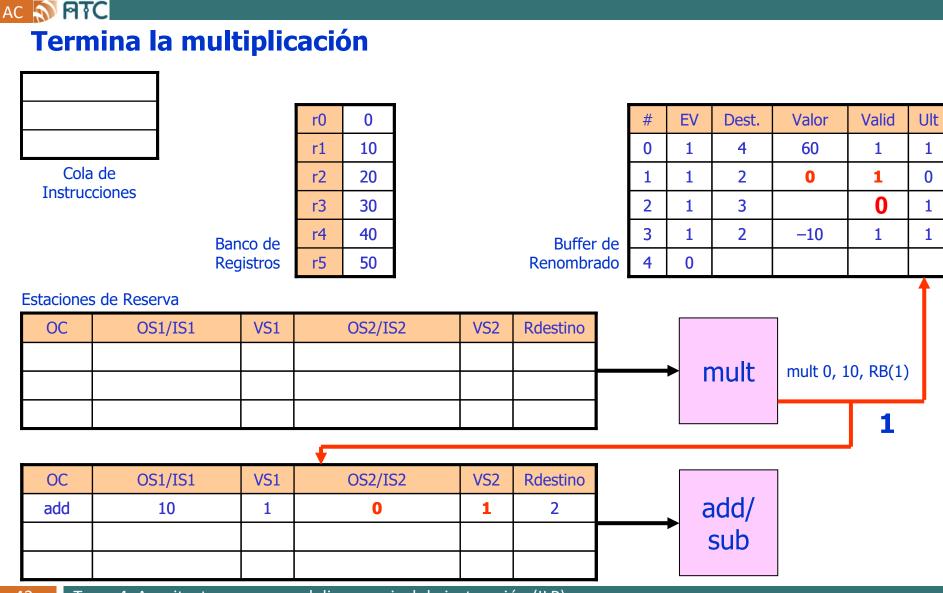
Renombrado

Rdestino

OC	OS1/IS1	VS1	OS2/IS2	VS2	Rdestino
add	10	1	1	0	2

add/ sub 0, 10, RB(3)

Algoritmo de Tomasulo V



Algoritmo de Tomasulo VI

Buffer de

Renombrado



Envío de la suma

Cola de Instrucciones

r0	0
r1	10
r2	20
r3	30
r4	40
r5	50

Banco de Registros

#	EV	Dest.	Valor	Valid	Ult
0	1	4	60	1	1
1	1	2	0	1	0
2	1	3		0	1
3	1	2	-10	1	1
4	0				

Estaciones de Reserva

OC	OS1/IS1	VS1	OS2/IS2	VS2	Rdestino	
						mult
						muit

OC	OS1/IS1	VS1	OS2/IS2	VS2	Rdestino			
						1	add/	-44 10 0 DB(2)
							sub	add 10, 0, RB(2)

Algoritmo de Tomasulo VII

Buffer de

Renombrado



Termina la suma

Cola de Instrucciones

r0 0
r1 10
r2 20
r3 30
r4 40
r5 50

Banco de Registros

EV Valor Valid Dest. Ult 60 1 1 4 1 2 0 0 3 10 1 1 3 2 -101 1 0

Estaciones de Reserva

OC	OS1/IS1	VS1	OS2/IS2	VS2	Rdestino	
						mult
						mult

OC	OS1/IS1	VS1	OS2/IS2	VS2	Rdestino

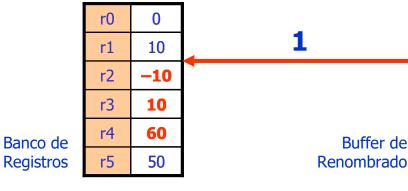
add/ sub add 10, 0, RB(2)

Algoritmo de Tomasulo VIII



Se actualizan los registros





#	EV	Dest.	Valor	Valid	Ult
0	1	4	60	1	1
1	1	2	0	1	0
2	1	3	10	1	1
3	1	2	-10	1	1
4	0				

Estaciones de Reserva

OC	OS1/IS1	VS1	OS2/IS2	VS2	Rdestino	
						mult
						mult

OC	OS1/IS1	VS1	OS2/IS2	VS2	Rdestino	
						add/
						sub

Para ampliar

AC A PTC

Artículos de Revistas:

- > Sussenguth, E.: "IBM's ACS-1 Machine". IEEE Computer, 22:11. Noviembre, 1999
- > Anderson, D.W.; Sparacio, F.J.; Tomasulo, R.M.: "The IBM 360 Model 91: Processor phylosophy and instruction handling". IBM J. Research and Development, 11:1, pp.8-24. Enero, 1967.
- ➤ Tomasulo, R.M.: "An efficient algorithm for exploiting multiple arithmetic units". IBM Res. And. Dev., 11:1, pp.25-33. Enero, 1967.
- Keller, R.M.: "Look-ahead processors". Computing Surveys, 7, pp.177-196. Diciembre, 1975. (Se introduce el término renombramiento de registros).

Para ampliar

AC SO PTC

Artículos de Revistas:

- Agerwala, T.; Cocke, J.: "High Performance Reduced Instruction Set Processors". IBM Tech. Report, Marzo, 1987.
 (Descripción del Proyecto América y de la generación del término Superescalar).
- > Wall, D.W.: "Limits of instruction-level parallelism". Research Rep. 93/6, DEC. Noviembre, 1993.

2º curso / 2º cuatr. Grados en Ing. Informática

Arquitectura de Computadores Tema 4

Lección 12. Consistencia del procesador y Procesamiento de Saltos

Material elaborado por Mancia Anguita y Julio Ortega Profesores: Mancia Anguita, Maribel García y Christian Morillas







Lecciones

AC A PIC

- Lección 11. Microarquitecturas ILP. Cauces Superescalares
- Lección 12. Consistencia del procesador y Procesamiento de Saltos
 - > Consistencia. Reordenamiento
 - > Procesamiento especulativo de saltos
- Lección 13. Procesamiento VLIW

Bibliografía

AC MATC

> Fundamental

- Capítulo 4. M. Anguita, J. Ortega: "Fundamentos y Problemas de Arquitectura de Computadores". Ed. Avicam. 2016.
- ➤ Capítulo 3, Secc. 3.3.4, 3.4, 3.5. J. Ortega, M. Anguita, A. Prieto. *Arquitectura de Computadores*. Thomson, 2005. ESIIT/C.1 ORT arq

Complementaria

➤ Sima and T. Fountain, and P. Kacsuk.

Advanced Computer Architectures: A Design Space

Approach. Addison Wesley, 1997. ESIIT/C.1 SIM adv

Contenido de la Lección 12

AC MATC

- > Consistencia. Reordenamiento
- Procesamiento especulativo de saltos

Consistencia I



En el **Procesamiento de una Instrucción** se puede distinguir entre:

- El Final de la Ejecución de la Operación codificada en las instrucciones
 (Se dispone de los resultados generados por las UF pero no se han modificado los registros de la arquitectura).
- El Final del Procesamiento de la Instrucción o momento en que se Completa la Instrucción (Complete o Commit)
 - (Se escriben los resultados de la Operación en los Registros de la Arquitectura. Si se utiliza un Buffer de Reorden, ROB, se utiliza el término Retirar la Instrucción, Retire, en lugar de Completar)

La **Consistencia** de un Programa se refiere a:

- El **orden** en que las instrucciones se **completan**
- El **orden** en que se **accede a memoria** para leer (LOAD) o escribir (STORE)

Cuando se ejecutan instrucciones en paralelo, el orden en que termina (*finish*) esa ejecución puede variar según el orden que las correspondientes instrucciones tenían en el programa pero debe existir consistencia entre el orden en que se completan las instrucciones y el orden secuencial que tienen en el código de programa.

Consistencia II



Consistencia de Procesador	Débil: Las instrucciones se pueden completar desordenadamente siempre que no se vean afectadas las dependencias	Deben detectarse y resolverse las dependencias	Power1 (90) PowerPC 601 (93) Alpha R8000 (94) MC88110 (93)
Consistencia en el orden en que se completan las instrucciones	Fuerte: Las instrucciones deben completarse estrictamente en el orden en que están en el programa	Se consigue mediante el uso de ROB	PowerPC 620 PentiumPro (95) UltraSparc (95) K5 (95) R10000 (96)
Consistencia de Memoria	Débil: Los accesos a memoria (Load/Stores) pueden realizarse desordenadamente siempre que no afecten a las dependencias	Deben detectarse y resolverse las dependencias de acceso a memoria	MC88110 (93) PowerPC 620 UltraSparc (95) R10000 (96)
Consistencia del orden de los accesos a memoria	Fuerte: Los accesos a memoria deben realizarse estrictamente en el orden en que están en el programa	Se consigue mediante el uso del ROB	PowerPC 601 (93) E/S 9000 (92)

Tendencia

Reordenamiento Load/Store I



Las instrucciones LOAD y STORE implican cambios en el Procesador y en Memoria

LOAD:

- Cálculo de Dirección en ALU o Unidad de Direcciones
- Acceso a Cache
- Escritura del Dato en Registro

STORE:

- Cálculo de Dirección en ALU o Unidad de Direcciones
- Esperar que esté disponible el dato a almacenar (en ese momento acaba)

La Consistencia de Memoria Débil (reordenación de los accesos a memoria):

'Bypass' de Loads/Stores:

Los Loads pueden adelantarse a los Stores pendientes y viceversa (siempre que no se violen dependencias)

Permite los Loads y Stores Especulativos:

Cuando un Load se adelanta a un Store que le precede antes de que se haya determinado la dirección se habla de Load especulativo. Igual para un Store que se adelanta a un Load o a un Store.

Permite ocultar las Faltas de Cache:

Si se adelanta un acceso a memoria a otro que dio lugar a una falta de cache y accede a Memoria Principal.

Reordenamiento Load/Store III

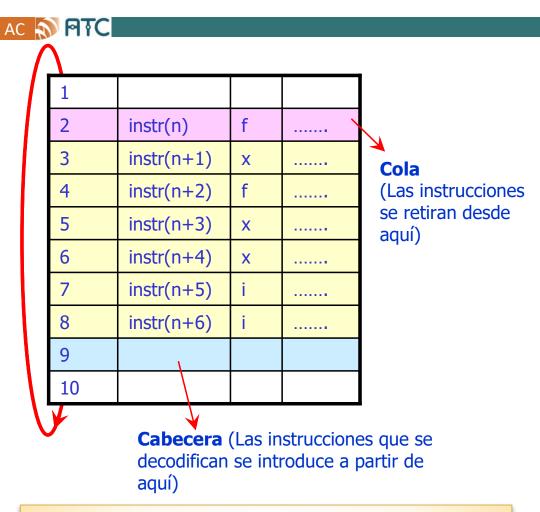
```
AC NATC
loop: Id r1, 0x1C(r2) \rightarrow Id r1, 0x1C(r2)
       mul r1, r1, r6 mul r1, r1, r6 \rightarrow ld r3, 0x2D(r2)
       st r1, 0x1C(r2) st r1, 0x1C(r2) mul r3, r3, r6 \rightarrow addi r2, r2, #1
                                                  st r3, 0x2D(r2) subi r4, r4, #1
       ld r3, 0x2D(r2) _____
                                                                        bnz r4, loop
       mul r3, r3, r6
       st r3, 0x2D(r2)
       addi r2, r2, #1
       subi r4, r4, #1
                           Se evita tener que esperar a las multiplicaciones y se pueden ir
       bnz r4, loop
                           adelantando c álculos correspondientes al control del n úmero de
                           iteraciones (suponiendo que hay renombrado)
```

```
Si se tuviera: st r1,0x1C(r2)
ld r3,0x2D(r7)

Las direcciones 0x1C(r2) y 0x2D(r7) podrían coincidir.

Se tendría un load especulativo
```

Buffer de Reordenamiento (ROB) I



La gestión de interrupciones y la ejecución especulativa se pueden implementar fácilmente mediante el ROB

- El puntero de cabecera apunta a la siguiente posición libre y el puntero de cola a la siguiente instrucción a retirar.
- Las instrucciones se introducen en el ROB en orden de programa estricto y pueden estar marcadas como emitidas (issued, i), en ejecución (x), o finalizada su ejecución (f)
- Las instrucciones sólo se pueden retirar (se produce la finalización con la escritura en los registros de la arquitectura) si han finalizado, y todas las que les preceden también.
- La consistencia se mantiene porque sólo las instrucciones que se retiran del ROB se completan (escriben en los registros de la arquitectura) y se retiran en el orden estricto de programa.

Buffer de Reordenamiento (ROB) II

AC NATC

Ejemplo de

uso del ROB I1: mult r1, r2, r3

I2: st r1, 0x1ca

I3: add r1, r4, r3

I4: xor r1, r1, r3



RAW: (I1,I2), (I3,I4)

WAR: (I2,I3), (I2,I4)

WAW: (I1,I3), (I1,I4), (I3,I4)

I1: Se puede empezar a ejecutar inmediatamente (se suponen disponibles r2 y r3)

12: Se envía a la unidad de almacenamiento hasta que esté disponible r1

I3: Se puede empezar a ejecutar inmediatamente (se suponen disponibles r4 y r3)

14: Se envía a la estación de reserva de la ALU para esperar a r1

Estación de Reserva (Unidad de Almacenamiento)

codop	dirección	op1	ok1
st	0x1ca	3	0

Estación de Reserva (ALU)

codop	dest	op1	ok1	op2	ok2
xor	6	_5	0	[r3]	1

Líneas del ROB

Buffer de Reordenamiento (ROB) III



Ciclo 7

#	codop	№ Inst.	Reg. Dest.	Unidad	Resultado	ok	marca
3	mult	7	r1	int_mult	-	0	х
4	st	8	-	store	-	0	i
5	add	9	r1	int_add	-	0	х
6	xor	10	r1	int_alu	-	0	i

Ciclo 9 No se puede retirar add aunque haya finalizado su ejecución

#	codop	Nº Inst.	Reg.Dest.	Unidad	Resultado	ok	marca
3	mult	7	r1	int_mult	1	0	х
4	st	8	-	store	1	0	i
5	add	9	r1	int_add	17	1	f
6	xor	10	r1	int_alu	-	0	х

Ciclo 10 Termina **xor**, pero todavía no se puede retirar

#	codop	Nº Inst.	Reg.Dest.	Unidad	Resultado	ok	marca
3	mult	7	r1	int_mult	-	0	х
4	st	8	-	store	-	0	i
5	add	9	r1	int_add	17	1	f
6	xor	10	r1	int_alu	21	1	f

Buffer de Reordenamiento (ROB) IV

AC MATC

Ciclo 12

#	codop	Nº Inst.	Reg. Dest.	Unidad	Resultado	ok	marca
3	mult	7	r1	int_mult	33	1	f
4	st	8	-	store	-	1	f
5	add	9	r1	int_add	17	1	f
6	xor	10	r1	int_alu	21	1	f

Ciclo 13

#	codop	Nº Inst.	Reg. Dest.	Unidad	Resultado	ok	marca
5	add	9	r1	int_add	17	1	f
6	xor	10	r1	int_alu	21	1	f

- Se ha supuesto que se pueden retirar dos instrucciones por ciclo.
- Tras finalizar las instrucciones **mult** y **st** en el ciclo 12, se retirarán en el ciclo 13.
- Después, en el ciclo 14 se retirarán las instrucciones add y xor.

Contenido de la Lección 12

AC MATC

- > Consistencia. Reordenamiento
- Procesamiento especulativo de saltos

Clasificación de los Saltos

Retorno de



Salto

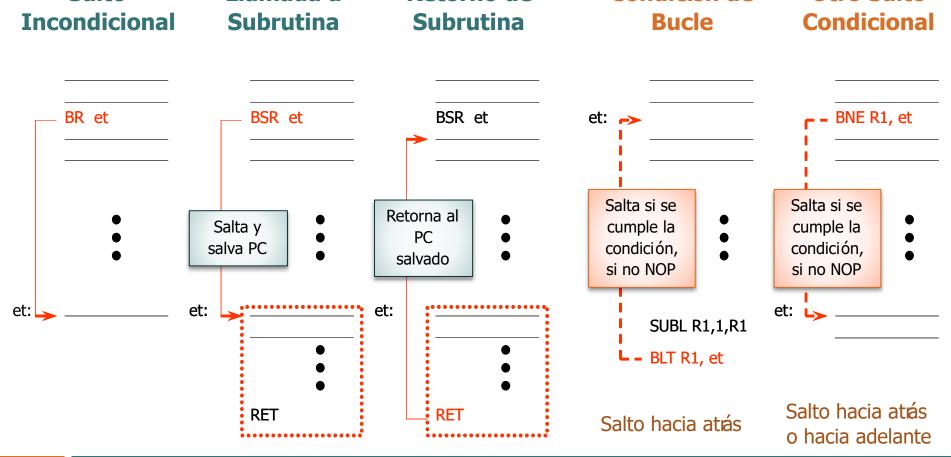
Saltos Incondicionales

Llamada a

Saltos Condicionales

Otro Salto

Condición de



Alternativas para la condición de salto



Estado del Resultado

Existen bits de Estado que se modifican al realizar operaciones o mediante operaciones que comprueban específicamente el valor de los registros

add r1,r2,r3 **beq cero** div r5,r4,r1

Dependencia que limita las Prestaciones en VLIW y superescalares

cero:

Ejemplos:

IBM/360, PDP-11, VAX, X-86, Pentium, PowerPC, Sparc

Comprobación Directa

Los resultados de las operaciones se comprueban directamente respecto a las condiciones específicas mediante instrucciones específicas

Dos Instrucciones

add r1,r2,r3 cmpeq r7, r1, 0 bt r7, cero div r5,r4,r1

cero:

Ejemplos:

Am 29000

Una Instrucción

add r1,r2,r3
bz r1, cero
div r5,r4,r1

cero:

Ejemplos:

Cray, MIPS, MC881X0, HP PA, DEC Alpha

Aspectos del Procesamiento de Saltos en un procesador Superescalar

AC A PTC

- Detección de la Instrucción de Salto
 - > Cuanto antes se detecte que una instrucción es de salto menor será la posible penalización. Los saltos se detectan usualmente en la fase de decodificación e incluso en la captación (si hay predecodificación).
- Gestión de los Saltos Condicionales no Resueltos
 - Si en el momento en que la instrucción de salto evalúa la condición de salto ésta no se haya disponible se dice que el salto o la condición no se ha resuelto. Para resolver este problema se suele utilizar el procesamiento especulativo del salto.
- Acceso a las Instrucciones destino del Salto
 - > Hay que determinar la forma de acceder a la secuencia a la que se produce el salto

El efecto de los saltos en los procesadores superescalares es más pernicioso ya que, al emitirse varias instrucciones por ciclo, *prácticamente en cada ciclo* puede haber una instrucción de salto.

Gestión de Saltos Condicionales no resueltos



Gestión de Saltos	Bloqueo del Procesamiento del Salto	Se bloquea la instrucción de salto hasta que la condición esté disponible (68020, 68030, 80386)		
Condicionales no Resueltos (Una condición de salto no se puede comprobar si no se ha	Procesamiento Especulativo de los Saltos	La ejecución prosigue por el camino más probable (se especula sobre las instrucciones que se ejecutarán). Si se ha errado en la predicción hay que recuperar el camino correcto. (Típica en los procesadores superescalares actuales)		
terminado de evaluar)	Múltiples Caminos	Se ejecutan los dos caminos posibles después de un salto hasta que la condición de salto se eval úa. En ese momento se cancela el camino incorrecto. (Máquinas VLIW experimentales: Trace/500, URPR2)		
Evitar saltos condicionales	Ejecución Vigilada (<i>Guarded Exec.</i>)	Se evitan los saltos condicionales incluyendo en la arquitectura instrucciones con operaciones condicionales (IBM VLIW, Cydra-5, Pentium, HP PA, Dec Alpha)		

Esquemas de Predicción de Salto



Predicción Fija

Se toma siempre la misma decisión: el salto siempre se realiza, 'taken', o no, 'not taken'

Predicción Verdadera

La decisión de si se realiza o no se realiza el salto se toma mediante:

Predicción Estática:

Según los atributos de la instrucción de salto (el código de operación, el desplazamiento, la decisión del compilador)

Predicción Dinámica:

Según el resultado de ejecuciones pasadas de la instrucción (historia de la instrucción de salto)



Predicción Estática

			_
	The same of		
A C			
ΔU	4		
\neg	1 N N		

Predicción basada en el Código de Operación Para ciertos códigos de operación (ciertos saltos condicionales específicos) se predice que el salto se toma, y para otros que el salto no se toma	MC88110 (93) PowerPC 603(93)
Predicción basada en el Desplazamiento del Salto Si el desplazamiento es positivo (salto hacia delante) se predice que no se toma el salto y si el desplazamiento es negativo (salto hacia atrás) se predice que se toma.	Alpha 21064 (92) PowerPC 603 (93)
Predicción dirigida por el Compilador El compilador es el que establece la predicción fijando, para cada instrucción, el valor de un bit específico que existe en la instrucción de salto (bit de predicción)	AT&T 9210 (93) PowerPC 603 (93) MC88110 (93)

Ejemplo: Predicción Estática en el MC88110

Formato	Instrucción		Predicción
	Condición Especificada	Bit 21 de la Instr.	Predicción
bcnd (<i>Branch</i> <i>Conditional</i>)	≠ 0	1	Tomado
	= 0	0	No Tomado
	> 0	1	Tomado
	< 0	0	No Tomado
	≥ 0	1	Tomado
	≤ 0	0	No Tomado
	bb1 (Branch on Bit Set)		Tomado
	bb0 (Branch on Bit Clear)		No Tomado

Predicción Dinámica

AC SO PIC

- La predicción para cada instrucción de salto puede cambiar cada vez que se va a ejecutar ésta según la historia previa de saltos tomados/no-tomados para dicha instrucción.
- El presupuesto básico de la predicción dinámica es que es más probable que el resultado de una instrucción de salto sea similar al que se tuvo en la última (o en las n últimas ejecuciones)
- Presenta mejores prestaciones de predicción, aunque su implementación es más costosa

Predicción Dinámica Implícita

No hay bits de historia propiamente dichos sino que se almacena la dirección de la instrucción que se ejecutó después de la instrucción de salto en cuestión

Predicción Dinámica Explícita

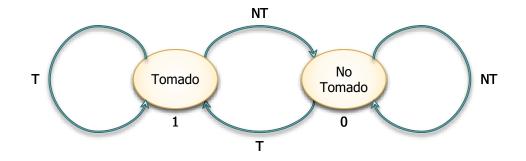
Para cada instrucción de salto existen unos bits específicos que codifican la información de historia de dicha instrucción de salto

Ejemplos de Procedimientos Explícitos de Predicción Dinámica de Saltos



Predicción con 1 bit de historia

La designación del estado, Tomado (1) o No Tomado (0), indica lo que se predice, y las flechas indican las transiciones de estado seg ún lo que se produce al ejecutarse la instrucción (T o NT)

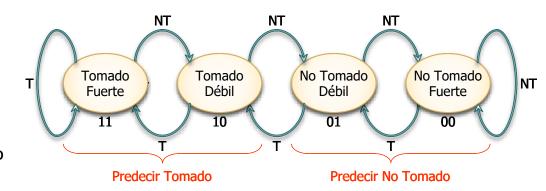


Predicción con 2 bits de historia

Existen cuatro posibles estados. Dos para predecir Tomado y otros dos para No Tomado

La primera vez que se ejecuta un salto se inicializa el estado con predicción estática, por ejemplo 11

Las flechas indican las transiciones de estado seg ún lo que se produce al ejecutarse la instrucción (T o NT)

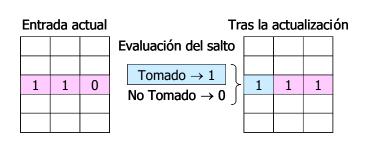


Predicción con 3 bits de historia

Cada entrada guarda las últimas ejecuciones del salto

Se predice según el bit mayoritario (por ejemplo, si hay mayoría de unos en una entrada se predice salto)

La actualización se realiza en modo FIFO, los bits se desplazan, introduciéndose un 0 o un 1 seg ún el resultado final de la instrucción de salto



Extensión del Procesamiento Especulativo

AC A PTC

- Tras la predicción, el procesador continúa ejecutando instrucciones especulativamente hasta que se resuelve la condición.
- El intervalo de tiempo entre el comienzo de la ejecución especulativa y la resolución de la condición puede variar considerablemente y ser bastante largo.
- En los procesadores superescalares, que pueden emitir varias instrucciones por ciclo, pueden aparecer más instrucciones de salto condicional no resueltas durante la ejecución especulativa.
- Si el número de instrucciones que se ejecutan especulativamente es muy elevado y la predicción es incorrecta, la penalización es mayor.

Así, cuanto mejor es el esquema de predicción mayor puede ser el número de instrucciones ejecutadas especulativamente.



- Nivel de Especulación: Número de Instrucciones de Salto Condicional sucesivas que pueden ejecutarse especulativamente (si se permiten varias, hay que guardar varios estados de ejecución). Ejemplos: Alpha21064, PowerPC 603 (1); Power 2 (2); PowerPC 620 (4); Alpha 21164 (6)
- Grado de Especulación: Hasta qué etapa se ejecutan las instrucciones que siguen en un camino especulativo después de un salto. Ejemplos: Power 1 (Captación); PowerPC 601 (Captación, Decodificación, Envío); PowerPC 603 (Todas menos la finalización)

Instrucciones de Ejecución Condicional (Guarded Execution)

AC N PTC

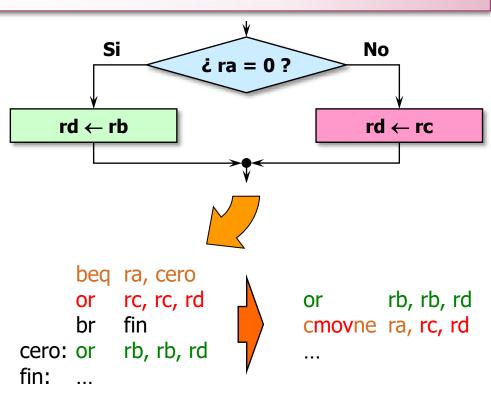
- Se pretende reducir el número de instrucciones de salto incluyendo en el repertorio máquina instrucciones con operaciones condicionales ('conditional operate instructions' o 'guarded instructions')
- Estas instrucciones tienen dos partes: la condición (denominada guardia) y la parte de operación

Ejemplo: cmovxx de Alpha

cmovxx ra.rq, rb.rq, rc.wq

- xx es una condición
- ra.rq, rb.rq enteros de 64 bits en registros ra y rb
- rc.wq entero de 64 bits en rc para escritura
- El registro ra se comprueba en relación a la condición xx y si se verifica la condición rb se copia en rc.

Sparc V9, HP PA, y Pentium ofrecen también estas instrucciones.



Para ampliar

AC A PIC

Artículos de Revistas:

- > Smith, J.E.: "A study of branch prediction strategies". Proc. Eighth Symp. on Computer Architecture, pp.135-148, 1981.
- > Smith, J.E.; Lee, J.: "Branch prediction strategies and branch target buffer design". IEEE Computer, pp.6-22. Enero, 1984.
- > Yeh, T.; Patt, Y.N.: "A comparison of dynamic branch prediction that use two levels of branch history". Proc. 20th Symp. On Computer Architecture, pp.257-266, 1993.
- Mahlke, S.A.: "A comparison of full and partial predicated execution support for ILP processors". Proc. 22nd Symp. On Computer Architecture, pp.138-150. Junio, 1995.
- > Smith, J.E.; Plezskun, A.R.: "Implementing Precise Interrupts in Pipelined Processors". IEEE Trans. On Computers, Vol.37, No.5, pp.562-573. Mayo, 1988.
- > Torng, H.C.; Day, M.: "Interrupt Handling of Out-of-Order Execution Processors". IEEE Trans. On Computers, Vol.42, No.1, pp.122-127. Enero, 1993.
- Walker, W.; Cragon, H.G.: "Interrupt Processing in Concurrent Processors". IEEE Computer, pp.36-46. Junio, 1995.
- Moudgill, M.; Vassiliadis, S.: "Precise Interrupts". IEEE Micro, pp.58-67. Febrero, 1996.
- > Samadzadeh, M.; Garalnabi, L.E.: "Hardware/Software Cost Analysis of Interrupt Processing Strategies". IEEE Micro, pp.69-76. Mayo-Junio, 2001.

AC A PTC

Páginas Web:

- http://www.delphion.com/research
 (Se pueden consultar las patentes sobre elementos de los procesadores. En particular las relativas a ROBs y elementos para mantener la consistencia secuencial en el procesador)
- http://www.aceshardware.com/Spades/read.php?article_id=51 (Artículo: J. De Gelas: "The Secrets of High Performance CPUs, Part2")

Artículos de Revistas:

> Smith, J.E.; Pleszkun, A.R.: "Implementing precise interrupts in pipelined processors". IEEE Trans. Computers, Vol.C37, pp.562-573. Mayo, 1988.

(Se propone por primera vez el uso del ROB)

Aviso

AC S PIC

"Con motivo de la suspensión temporal de la actividad docente presencial en la UGR, se informa de las condiciones de uso de la aplicación de videoconferencia que a continuación se va a utilizar:

- 1. La sesión va a ser grabada con el objeto de facilitar al estudiantado, con posterioridad, el contenido de la sesión docente.
- 2. Se recomienda a los asistentes que desactiven e inhabiliten la cámara de su dispositivo si no desean ser visualizados por el resto de participantes.
- 3. Queda prohibida la captación y/o grabación de la sesión, así como su reproducción o difusión, en todo o en parte, sea cual sea el medio o dispositivo utilizado. Cualquier actuación indebida comportará una vulneración de la normativa vigente, pudiendo derivarse las pertinentes responsabilidades legales."

2º curso / 2º cuatr.

Grados en
Ing. Informática

Arquitectura de Computadores Tema 4

Lección 13. Procesamiento VLIW

Material elaborado por Mancia Anguita y Julio Ortega Profesores: Mancia Anguita, Maribel García y Christian Morillas







Bibliografía

AC A PIC

Fundamental

- Capítulo 4. M. Anguita, J. Ortega. Fundamentos y Problemas de Arquitectura de Computadores. Ed. Avicam, 2016
- > Capítulo 5. J. Ortega, M. Anguita, A. Prieto. *Arquitectura de Computadores*. Thomson, 2005. ESIIT/C.1 ORT arq

Complementaria

Sima and T. Fountain, and P. Kacsuk.
Advanced Computer Architectures: A Design Space
Approach. Addison Wesley, 1997. ESIIT/C.1 SIM adv

Contenido de la Lección 13

AC A PIC

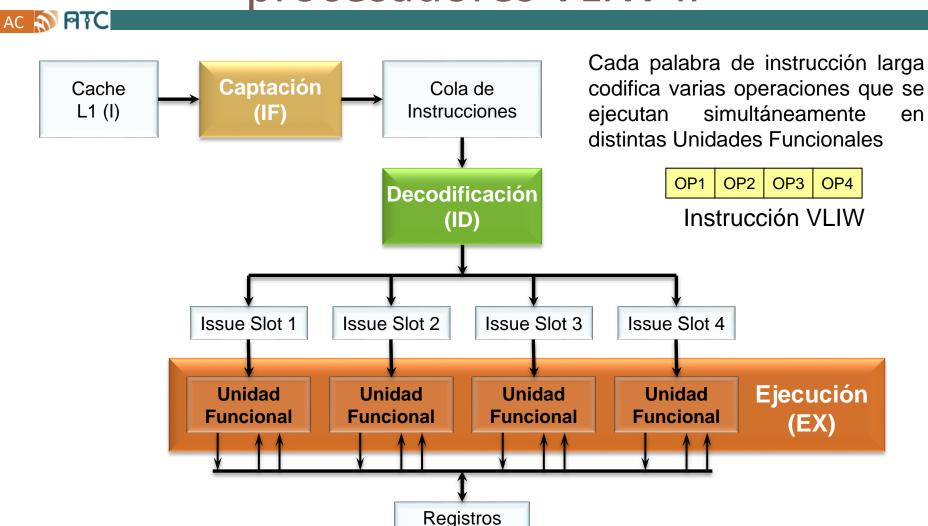
- Características generales y motivación (ILP hardware vs. ILP software)
- > Planificación estática
- Procesamiento especulativo

Características generales de los procesadores VLIW I

AC A PIC

- Las arquitectura VLIW utilizan varias unidades funcionales independientes.
- En lugar de tratar de enviar varias instrucciones independientes a las unidades funcionales, una arquitectura VLIW empaqueta varias operaciones en una única instrucción (muy larga, Very Long, por ejemplo, entre 112 y 128 bits) u ordena las instrucciones en el paquete de emisión con las mismas restricciones de independencia.
- La decisión de qué instrucciones se deben emitir simultáneamente corresponde al compilador (hardware más sencillo que el de un superescalar).
- Las ventajas de la aproximación VLIW crecen a medida que se pretende emitir más instrucciones por ciclo (el hardware adicional para un superescalar que emita dos instrucciones por ciclo es relativamente pequeño, pero crece a medida que se pretenden emitir más instrucciones por ciclo)

Características generales de los procesadores VLIW II



de la Arquitectura

Contenido de la Lección 13

AC A PTC

- Características generales y motivación (ILP hardware vs. ILP software)
- > Planificación estática
- Procesamiento especulativo

El papel del Compilador

AC A PTC

Planificación estática

Necesita asistencia del compilador, que puede realizar renombrados, reorganizaciones de código, etc., para mejorar el uso de los recursos disponibles, el esquema de predicción de saltos,...

Planificación dinámica

Requiere menos asistencia del

compilador pero más coste hardware.

Facilita la portabilidad del código entre la misma familia de procesadores



El compilador construye paquetes de instrucciones (*ventanas de emisión*) sin dependencias, de forma que el procesador no necesita comprobarlas explícitamente.

Planificación Estática I



for
$$(i = 1000 ; i > 0 ; i = i - 1)$$

 $x[i] = x[i] + s;$



loop: Id f0, 0(r1)
addd f4, f0, f2
sd f4, 0(r1)
subui r1, r1, #8
bne r1, loop

Existen dependencias RAW entre cada dos instrucciones consecutivas, y además existe una instrucción de salto que controla el final del bucle: Parece que no se puede aprovechar mucho ILP

Planificación Estática II

AC MATC

Suponiendo que hay suficientes unidades funcionales para la suma, y que cuando hay dependencias de tipo RAW (las de tipo WAW y WAR las puede evitar el compilador mediante renombrado) los retardos introducidos son:

Instrucción que produce el resultado	Instrucción que usa el resultado	Latencia
Operación FP	Operación FP	3
Operación ALU	Store	2
Load	Operación FP	1
Load	Store	0

	Opción 1 (Sin desenrollar)	Opción 2 (Sin desenrollar)	Ciclos
loop	ld f0,0(r1)	ld f0,0(r1)	1
		subui r1,r1,#8	2
	addd f4,f0,f2	addd f4,f0,f2	3
			4
		bne r1,loop	5
	sd f4,0(r1)	sd f4,8(r1)	6
	subui r1,r1,#8		7
			8
	bne r1,loop		9
			10

Planificación Estática III

AC DIP	1iC			
	Instrucción E	ntera Instrucción FP	Load/Store	Ciclo
loo	subui r1, r1,	‡ 8	ld f0, 0(r1)	1
				2
		addd f4, f0, f2		3
				4
	bne r1, loop			5
			sd f4, 0(r1)	6
	Slot 1	Slot 2	Slot 3	

La arquitectura VLIW no ganaría nada frente a la opción 2 del bucle sin desenrollar. Además, se necesitarían 12 palabras en el código VLIW frente a las 5 que se utilizaría en la codificación escalar.

Planificación estática local y global

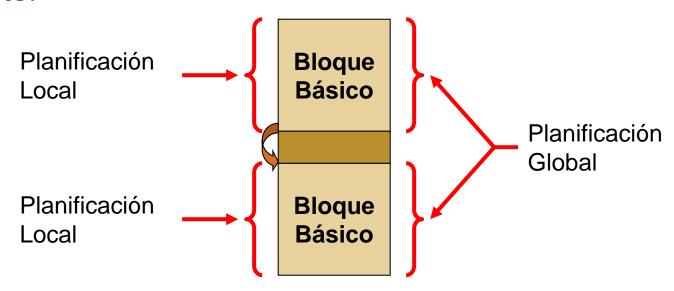
AC A PIC

Planificación local:

actúa sobre un bloque básico (mediante desenrollado de bucles y planificación de las instrucciones del cuerpo aumentado del bucle).

> Planificación global:

actúa considerando bloques de código entre instrucciones de salto.



Planificación Estática Local

AC N PTC

Desenrollado de bucles:

- Al desenrollar un bucle se crean bloques básicos más largos, lo que facilita la planificación local de sus sentencias
- > Además de disponer de más sentencias, éstas suelen ser independientes, ya que operan sobre diferentes datos

Segmentación software (software pipelining):

- Se reorganizan los bucles de forma que cada iteración del código transformado contiene instrucciones tomadas de distintas iteraciones del bloque original
- > De esta forma se separan las instrucciones dependientes en el bucle original entre diferentes iteraciones del bucle nuevo

Planificación Estática con Desenrollado de Bucles I

AC A PTC

for
$$(i = 1000 ; i > 0 ; i = i - 1)$$

 $x[i] = x[i] + s;$





Existen dependencias RAW entre cada dos instrucciones consecutivas, y además existe una instrucción de salto que controla el final del bucle: Parece que no se puede aprovechar mucho ILP

```
loop:
          ld
                    f0, 0(r1)
                    f6, -8(r1)
          ld
                    f10, -16(r1)
          ld
          ld
                    f14, -24(r1)
                    f18, -32(r1)
          ld
                    f4, f0, f2
          addd
                    f8, f6, f2
          addd
                    f12, 10, f2
          addd
          addd
                    f16, f14, f2
          addd
                    f20, f18, f2
                    f4, 0(r1)
          sd
                    f8, -8(r1)
          sd
                    f12, -16(r1)
          sd
                    f16, -24(r1)
          sd
                    f20, -32(r1)
          sd
          subui
                    r1, r1, #40
                    r1, loop
          bne
```

El desenrollado pone de manifiesto un mayor paralelismo ILP

Planificación Estática con Desenrollado de Bucles II

	Slot 1	Slot 2	Slot 3	
			sd f20, 8(r1)	10
	bne r1, loop		sd f16, 16(r1)	9
			sd f12, 24(r1)	8
	subui r1, r1, #40	addd f20, f18, f2	sd f8, –8(r1)	7
		addd f16, f14, f2	sd f4, 0(r1)	6
		addd f12, f10, f2	ld f18, –32(r1)	5
		addd f8, f6, f2	ld f14, –24(r1)	4
		addd f4, f0, f2	ld f10, –16(r1)	3
			ld f6, 0(r1)	2
loop			ld f0, 0(r1)	1
	Instrucción Entera	Instrucción FP	Load/Store	Ciclo
₩ HTC				

Se tardarían 10x(1000/5)=2000 ciclos, frente a los 10x1000=10000 ó 6x1000=6000 ciclos del bucle sin desenrollar.

Planificación Estática con Segmentación Software I

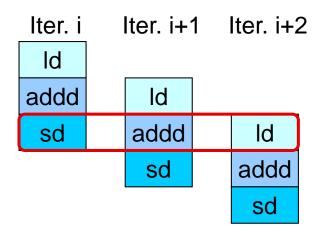
AC AC PIC

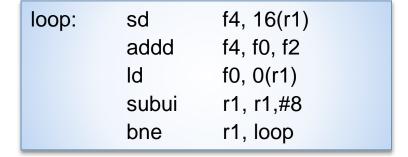
for
$$(i = 1000 ; i > 0 ; i = i - 1)$$

 $x[i] = x[i] + s;$



loop:	ld	f0, 0(r1)	
	addd	f4, f0, f2	
	sd	f4, 0(r1)	
	subui	r1, r1, #8	
	bne	r1, loop	







Iter. i:	ld addd sd	f0, 16(r1) f4, f0, f2 f4, 16(r1)
Iter. i+1:	ld addd sd	f0, 8(r1) f4, f0, f2 f4, 8(r1)
Iter. i+2:	ld addd sd	f0, 0(r1) f4, f0, f2 f4, 0(r1)

Planificación Estática con Segmentación Software II



	Instrucción Enter	ra Instrucción FP	Load/Store	Ciclo
loop		addd f4,f0,f2	sd f4,16(r1)	1
	subui r1,r1,#8		ld f0,0(r1)	2
				3
	bne r1,loop			4
				5
	Slot 1	Slot 2	Slot 3	

- Se tardarían 5x1000=5000 ciclos (algunos más si se consideran las instrucciones previas al inicio del bucle con segmentación software y las posteriores al final del bucle).
- Si se desenrolla este bucle ya segmentado, se pueden mejorar mucho más las prestaciones.

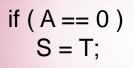
Planificación estática global

AC SO PIC

- La planificación global mueve código a través de los saltos condicionales (que no correspondan al control del bucle)
- Se parte de una estimación de las frecuencias de ejecución de las posibles alternativas tras una instrucción de salto condicional
- > Apoyo para facilitar la planificación global:
 - Instrucciones con predicado y
 - > Especulación

Instrucciones de Ejecución Condicional







bnez r1, L add r2, r3, 0 ; r3=T



cmovz r2, r3, r1

Si se verifica la condición en el último operando (r1=0 en este caso) se produce el movimiento entre los otros dos operandos $(r2 \leftarrow r3)$



$$r2 \leftarrow r1$$

 $r2 \leftarrow -r1$ (condicional a que $r1 < 0$)

Instrucciones con Predicado I

AC NATC

Ejemplo de Ejecución VLIW (con dos slots)



rs)	¿a && b == 1?	no
si	si ¿c ==	1? no
j = j + 1	k = k + 1	k = k - 1
	i = i + 1	

Slot 1	Slot 2
[1]	[2]
[3]	[4]
[5]	[10]
[7]	[6]
[8]	[9]



Se eliminan todos los saltos. Las dependencias de control pasan a ser dependencias de datos

[1]	P1, P2 = cmp (a==0)	
[2]	P3 = cmp (a!=a)	
[3]	P4 = cmp (a!=a)	
[4]	P5 = cmp (a!=a)	
[5] <p2></p2>	P1, P3 = cmp (b==0)	(Si a=1)
[6] <p3></p3>	add j, j, 1	(Si a=1 y b=1)
[7] <p1></p1>	P4, P5 = cmp (c!=0)	(Si a=0 ó b=0)
[8] <p4></p4>	add k, k, 1	(Si c=1)
[9] <p5></p5>	sub k, k, 1	(Si c=0)
[10]	add i, i, 1	

Contenido de la Lección 13

AC A PTC

- Características generales y motivación (ILP hardware vs. ILP software)
- > Planificación estática
- Procesamiento especulativo

Procesamiento Especulativo

AC A PTC

El **procesamiento especulativo se basa en la predicción** de que determinada instrucción, condición, etc. será muy probable, para adelantar su procesamiento, mejorando las prestaciones del procesador.

El procesamiento especulativo tiene un coste si la predicción que se ha hecho no es correcta. Este coste va desde el correspondiente a haber ejecutado una instrucción que no tendría que haberse ejecutado, hasta la necesidad de incluir código que deshaga el efecto de la operación implementada, vigilar el comportamiento frente a las excepciones, etc.

Slot 1	Slot 2
lw r1,40(r2)	add r3,r4,r5
	add r6,r3,r7
beqz r10,loop	
lw r8,0(r10)	
lw r9,0(r8)	

Slot 1	Slot 2
lw r1,40(r2)	add r3,r4,r5
lwc r8,0(r10),r10	add r6,r3,r7
beqz r10,loop	
lw r9,0(r8)	

Se produce el lw r8,0(r10) si r10!=0

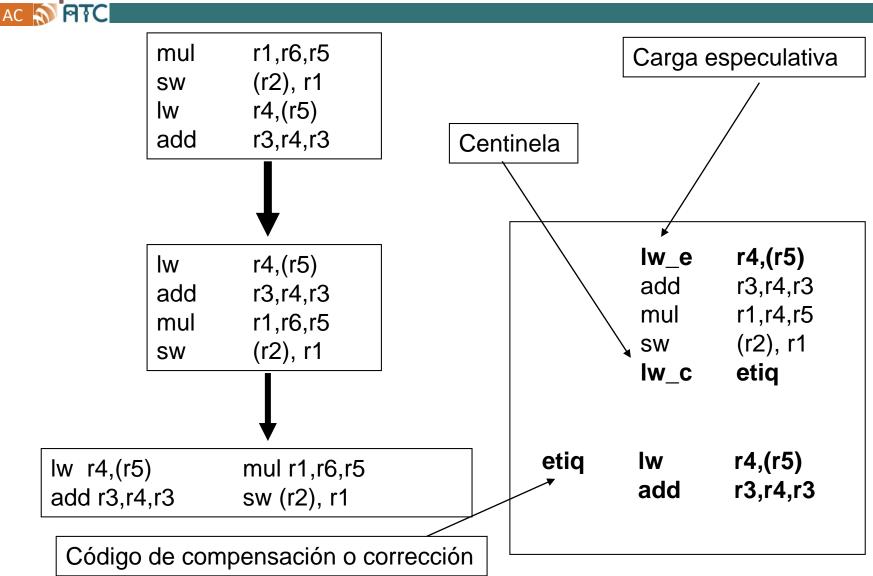
Se aprovecha el slot de acceso a memoria. Si **beqz** da lugar al salto se ha ejecutado una instrucción de forma innecesaria. **Otro problema son las excepciones**

Uso de Centinelas para Permitir la Especulación de las Referencias a Memoria

AC M PTC

- Cuando no existe ninguna ambigüedad, el compilador adelanta los LOADs con respecto a los STOREs para reducir la longitud del camino crítico en el código
- Cuando existe ambigüedad:
 - > Se incluye en la arquitectura una instrucción para comprobar los conflictos de direcciones.
 - > La instrucción se sitúa en la posición original del LOAD (centinela)
 - Cuando se ejecuta el LOAD especulativo, el hardware guarda la dirección a la que se ha realizado el acceso.
 - > Si los sucesivos STOREs no han accedido a esa dirección, la especulación es correcta. En caso contrario, la especulación ha fallado.
 - Si la especulación ha fallado:
 - Si la especulación afecta al LOAD solamente, se vuelve a ejecutar cuando se llega al centinela.
 - Si se han ejecutado instrucciones que dependen del LOAD habrá que repetir todas esas instrucciones (se necesita mantener información de todas ellas en un trozo de código cuya dirección se incluye en la instrucción centinela)

Uso de Centinelas para Permitir la Especulación de las Referencias a Memoria



Especulación Software vs. Hardware

AC PTC

Al final, los procesadores que implementan ILP intensivo en hardware han acabado tomando ideas de la especulación software y viceversa:

Técnicas Software en ILP intensivo en Hardware

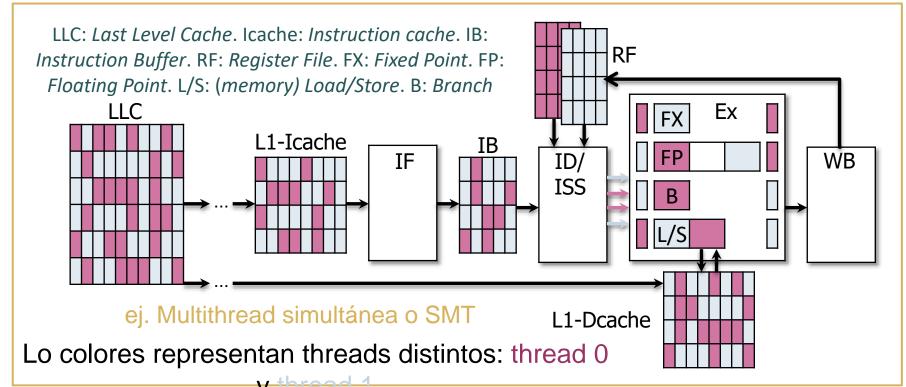
- Soporte para instrucciones condicionales
- Precaptación de instrucciones y otros elementos para mejorar el acceso a caches
- Elementos para la predicción de saltos
- Soporte especial para los LOADs especulativos

Técnicas Hardware en ILP intensivo en Software

- Planificación de instrucciones utilizando campos de marca
- Predicción dinámica de saltos
- Soporte para procesamiento de excepciones
- Hardware para verificar la corrección de LOADs especulativos

Modificación de la arquitectura ILP en Core Multithread ()





- > Almacenamiento: se multiplexa, reparte o comparte entre threads, o se replica
 - Con SMT: repartir, compartir o replicar
- Otro hardware en etapas: se multiplexa, reparte o comparte entre threads
 - Con SMT: unidades funcionales (etapa Ex) compartidas, resto etapas repartidas, compartidas; multiplexación es posible (p. ej. predicción de saltos y decodificación)

Clasificación de cores multithread

AC A PTC



- Ejecutan varios threads concurrentemente en el mismo core
- La conmutación entre threads la decide y controla el hardware
- > Emite instrucciones de un único thread en un ciclo
- Simultaneous MultiThreading (SMT) o multihilo simultáneo o horizontal multithread
 - Ejecutan, en un core superescalar, varios threads en paralelo
 - Pueden emitir (para su ejecución) instrucciones de varios threads en un ciclo

Clasificación de cores con TMT

AC SO PTC

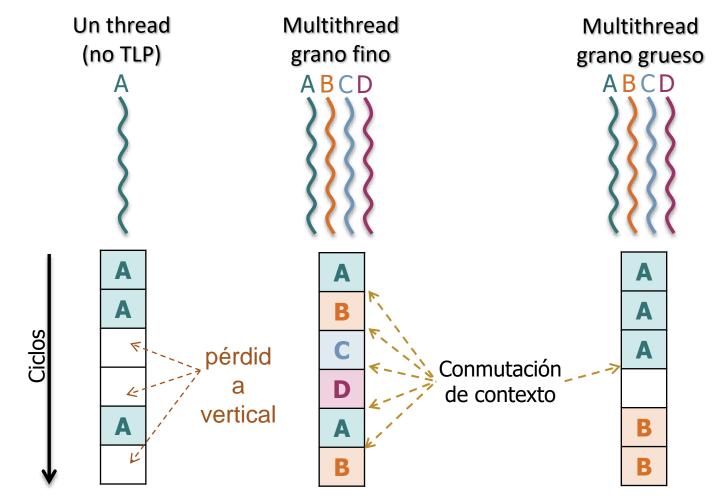
- ABCD SopiD
- Fine-grain multithreading (FGMT) o interleaved multithreading
 - La conmutación entre threads la decide el hardware cada ciclo (coste 0)
 - por turno rotatorio (round-robin) o
 - por eventos de cierta latencia combinado con alguna técnica de planificación (ej. thread menos recientemente ejecutado)
 - Eventos: dependencia funcional, acceso a datos a cache L1, salto no predecible, una operación de cierta latencia (ej. div), ...
- Coarse-grain multithreading (CGMT) o blocked multithreading
 - La conmutación entre threads la decide el hardware (coste de 0 a varios ciclos)
 - tras intervalos de tiempo prefijados (timeslice multithreading) o
 - por eventos de cierta latencia (switch-on-event multithreading).

В

Alternativas en un core escalar segmentado

AC A PTC

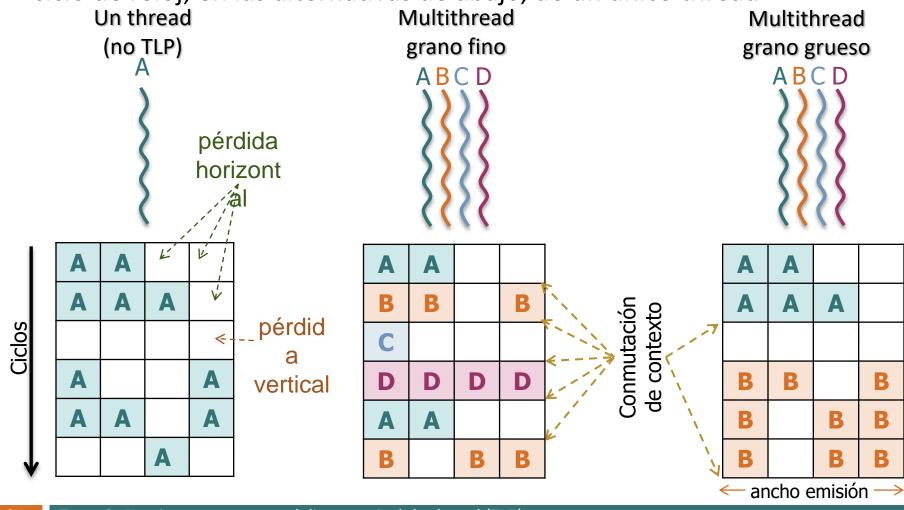
En un core escalar se emite una instrucción cada ciclo de reloj



Alternativas en un core con emisión múltiple de instrucciones de un thread

AC A PTC

En un core superescalar o VLIW se emiten más de una instrucción cada ciclo de reloj; en las alternativas de abajo, de un único thread



Core multithread simultánea y multicores

AC SO PIC

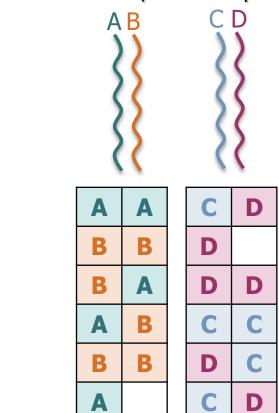
En un multicore y en un core superescalar con SMT (Simultaneous MultiThread) se pueden emitir instrucciones de distintos threads cada ciclo de reloj

Core con multithread simultánea (4 thread por core)



	A	A	D	В	
Ciclos	В	В			
	C	D	В	В	
	D	A		D	
	A		С	С	
\downarrow	В	С	D	D	
-	← aı	ncho e	emisić	n —	

Multicore con 2 cores con multithread simultánea (2 threads por core)



Hardware y arquitecturas TLP en un chip



Hardware	CGMT	FGMT	SMT	СМР
Registros	replicado (al menos PC)	replicado	replicado	replicado
Almacenamiento	multiplexado	multiplexado, compartido, repartido o replicado	compartido, repartido o replicado	replicado
Otro hardware de las etapas del cauce	multiplexado	Captación: repartida o compartida; Resto: multiplexadas	<u>UF</u> : compartidas; <u>Resto</u> : repartidas o compartidas	replicado
Etiquetas para distinguir el thread de una instr.	Sí	Sí	Sí	No
Hardware para conmutar entre threads	Sí	Sí	No	No

AC N PTC

Webs

- An Introduction to the Intel® QuickPath Interconnect, http://www.intel.com/content/www/us/en/io/quickpathtechnology/quick-path-interconnect-introduction-paper.html
- Intel® QuickPath Technology Animated Demo [119 K] http://www.intel.com/content/www/us/en/performance/perfor mance-quickpath-architecture-demo.html

Artículos en revistas

Kongetira, P.; Aingaran, K.; Olukotun, K.; , "Niagara: a 32-way multithreaded Sparc processor," *Micro, IEEE* , vol.25, no.2, pp. 21-29, March-April 2005. Disponible en línea (biblioteca UGR): http://ieeexplore.ieee.org/stamp/stamp.jsp?tp=&arnumber=1453485&isnumber=31213

AC A PTC

- Páginas Web:
 - http://www.research.ibm.com/vliw (Investigación sobre VLIW en IBM).
- Artículos de Revistas:
 - ➤ Fisher, J.A.: "Very Long Instruction Word Architectures and ELI-512". Proc. 10th Symp. On Computer Architecture, pp.140-150, 1983. (Aparece el término VLIW).
 - > Rau, B.R.; et al.: "The Cydra 5 departamental supercomputer: design philosophies, decisions, and tradeoffs". IEEE Computers, pp.22-34, 22:1, 1989.

AC A PTC

Páginas Web:

- http://www.cs.ucsd.edu/classes/sp00/cse231/mdes.pdf (artículo sobre compiladores para VLIW y EPIC)
- http://www.compilerconnection.com/index.html (página bastante completa con información relativa a compiladores: compañías, investigación, grupos de noticias,...)

Artículos de Revistas:

- ➤ Lam, M.: "Software Pipelining: An effective scheduling technique for VLIW processors". Proc. ACM SIGPLAN Conf. Prog. Lang. Design and Implementation, pp.318-328, 1988.
- Wilson, R.P.; Lam, M.: "Efficient context-sensitive pointer analysis for C programs". Proc. ACM SIGPLAN Conf. Prog. Lang. Design and Implementation, pp.1-12, 1995.
- Mahlke, S.A., et al.: "Sentinel Scheduling for VLIW and superscalar processors". Proc. 5th Conf. On Architectural Support for Prog. Languages and Operating Systems, pp.238-247, 1992.